

Análisis Exploratorio de Datos (EDA): Descubriendo el Corazón de tus Datos

By: Geisler Aldana Tuberquia



¿Qué es el EDA? Una Definición

Definición

El **Análisis Exploratorio de Datos (EDA)** es una filosofía de análisis de datos que utiliza técnicas — principalmente gráficas— para maximizar la comprensión de un conjunto de datos, descubrir estructuras subyacentes y extraer variables importantes.

Génesis

John Tukey (1977) lo impulsó como un proceso de **“trabajo detectivesco”**: observar pistas en los datos antes de formular hipótesis formales.

Filtro crítico frente al fenómeno conocido como "Garbage In, Garbage Out" (GIGO)

Análoga al proceso de depuración (debugging) de una aplicación compleja

¿Por qué Explorar Antes de Analizar?



Sin EDA

Como un detective sin lupa: imposible descubrir pistas ocultas



Primera Cita

Tu primer encuentro con los datos: entenderlos antes de enamorarte de conclusiones

Objetivos Clave del EDA

- Comprender la distribución de las variables numéricas y categóricas
- Identificar relaciones entre diferentes variables
- Detectar valores atípicos y errores en la recopilación



El EDA: Un Viaje de Descubrimiento



Generar Hipótesis

No confirmar, sino descubrir nuevas preguntas



Proceso Iterativo

Cada visualización te lleva a explorar más



Herramientas Clave

Estadísticas de resumen y visualizaciones

¡A la Vista! Herramientas Visuales Clave



Histogramas

¿Cómo se distribuyen tus datos? Revelan forma, centro y dispersión de variables numéricas



Diagramas de Barras

Frecuencia de categorías para variables cualitativas. Perfecto para comparar grupos




Gráficos Circulares

Proporciones de un todo, pero úsalos con precaución para evitar malentendidos

Explorando Relaciones: ¿Cómo se Llevan las Variables?

Diagramas de Dispersión

La relación entre dos variables numéricas. ¿Correlación positiva, negativa o nula? Cada punto revela un patrón oculto.



Detectando Anomalías: Los "Valores Atípicos"

¿Qué son?


Puntos que se salen de la norma: ¿errores de medición o descubrimientos revolucionarios?

Identificación

Los diagramas de caja son excelentes para detectarlos visualmente con su estructura de cuartiles

Tratamiento

Crucial para no sesgar análisis posteriores. Investiga su origen antes de eliminarlos



El Poder de Python y R en EDA



Python

Estándar en ciencia de datos con librerías poderosas: **Pandas** para manipulación, **Matplotlib** y **Seaborn** para visualizaciones elegantes y profesionales



R

Enfoque estadístico nativo con **ggplot2** para visualizaciones complejas y publicables. Ideal para análisis riguroso y reproducible



Recursos

La guía de datos.gob.es ofrece excelentes tutoriales y ejemplos prácticos para iniciarse en ambas herramientas



Tu Próximo Paso: ¡Explora tus Datos!

Base del Éxito

El EDA es el cimiento de cualquier análisis de datos exitoso y fiable

Transformación

Convierte datos brutos en información valiosa y accionable

Empieza Hoy

¡Haz preguntas a tus datos ahora mismo!